

深度残差学习在图像识别中的应用

何开明

张翔宇

任少清

孙健微软

研究院


{kahe, v-xiangz, v-shren, jiansun}@microsoft.com

摘要

更深的神经网络更难训练。我们提出一种残差学习框架，以简化比先前网络更深的网络训练过程。我们明确地将层重新定义为学习残差函数，参考层输入、层输出以及层间残差。

与其学习未引用的函数，我们提供了全面的实证证据，表明这些残差网络更易于优化，且能通过大幅增加深度来提升准确率。在ImageNet数据集上，我们评估了深度达152层的残差网络——其深度是VGG网络[40]的8倍，但复杂度仍更低。通过残差网络集成模型，我们在ImageNet测试集上实现了3.57%的误差率，该成绩在ILSVRC 2015分类任务中夺得冠军。我们还针对CIFAR-10数据集进行了100层与1000层模型的分析。

表征深度对许多视觉识别任务至关重要。仅凭我们极其深层的表征，就在COCO目标检测数据集上实现了28%的相对提升。深度残差网络是我们提交至ILSVRC与COCO 2015竞赛¹的基础架构，在ImageNet检测、ImageNet定位、COCO检测及COCO分割任务中均斩获冠军。



¹<http://image-net.org/challenges/LSVRC/2015/> 以及
<http://mscoco.org/dataset/#detections-challenge2015>。

1. 引言

深度卷积神经网络[22, 21]在图像分类领域取得了一系列突破性进展[21, 49, 39]。这类深度网络以端到端的多层架构自然整合了低/中/高阶特征[49]与分类器，且特征的“层次”可通过堆叠层数（深度）得到增强。最新研究[40, 43]表明网络深度至关重要，在具有挑战性的ImageNet数据集[35]上取得的领先成果[40, 43, 12, 16]均采用深度达十六层[40]至三十层[16]的“超深”模型[40]。许多其他非平凡的视觉识别任务[7, 11, 6, 32, 27]也同样

图1. CIFAR-10数据集上

采用20层和56层“基础”网络的训练误差（左）与测试误差（右）。更深层网络呈现更高训练误差，进而导致测试误差上升。ImageNet数据集的类似现象见图4。

深度模型带来了巨大收益。

深度的重要性引发了一个问题：*学习更优网络是否仅需堆叠更多层？*而阻碍解答此问题的正是臭名昭著的梯度消失/爆炸问题[14, 1, 8]，该问题从一开始就阻碍了收敛。然而，归一化初始化[23, 8, 36, 12]和中间归一化层[16]已基本解决了该问题，使数十层网络能够通过反向传播的随机梯度下降法(SGD)[22]开始收敛。

当更深层网络开始收敛时，却暴露了*性能退化*问题：随着网络深度增加，准确率先趋于饱和（这或许不足为奇），随后急剧下降。出乎意料的是，这种退化*并非由过拟合引起*。正如文献[10,41]所述并经我们实验充分验证，在深度适中的模型中增加更多层反而会导致*训练误差上升*。图1展示了典型案例。

训练准确度的下降表明并非所有系统都同样容易优化。让我们考虑一种较浅的架构及其更深的对应模型——后者在前者基础上增加了更多层。*通过构造方法*，我们能为更深的模型找到解：新增层采用恒等映射，其余层则从已训练的浅层模型中复制而来。这种构造解的存在表明，更深的模型产生的训练误差不应高于其浅层对应模型。但实验表明，我们现有的求解器无法找到满足以下条件的解：




图2. 残差学习：构建模块。

其性能可与构造解媲美或更优（或无法在合理时间内实现）。

本文通过引入深度残差学习框架解决性能退化问题。我们不再期望每层直接拟合目标底层映射，而是明确让各层拟合残差映射。形式化地，设目标底层映射为 $H(x)$ ，则让堆叠的非线性层拟合另一映射 $F(x) := H(x) - x$ 。原始映射由此重构为 $F(x) + x$ 。我们假设优化残差映射比优化原始无参照映射更为容易。极端情况下，若恒等映射为最优解，则将残差推至零比通过非线性层堆叠拟合恒等映射更为简单。

$F(x) + x$ 的表达式可通过具有“捷径连接”的前馈神经网络实现（图 2）。捷径连接[2, 33, 48]指跳过一层或多层的连接。在本例中，捷径连接仅执行恒等映射，其输出与堆叠层的输出相加（图 2）。恒等短路连接既不增加额外参数也不提升计算复杂度。整个网络仍可通过带反向传播的梯度下降法进行端到端训练，且无需修改求解器即可使用通用库（如Caffe[19]）轻松实现。

我们通过ImageNet[35]开展全面实验
[35] 数据集进行全面实验，揭示了性能退化问题并评估本方法。实验表明：1) 我们的超深残差网络易于优化，而仅堆叠层数的“普通”网络在深度增加时训练误差更高；2) 我们的深残差网络能通过大幅增加深度轻松获得精度提升，产出结果显著优于现有网络。

在CIFAR-10数据集[20]上也观察到类似现象，表明优化难题及本方法的效果并非仅限于特定数据集。我们在此数据集上成功训练出超过100层的模型，并探索了超过1000层的模型架构。

在ImageNet分类数据集[35]上，我们通过极深的残差网络获得了卓越结果。我们的152层残差网络是迄今在ImageNet上提出的最深网络，其复杂度仍低于VGG网络[40]。我们的集成模型在该数据集上实现了3.57%的top-5错误率。

ImageNet测试集，并在ILSVRC 2015分类竞赛中夺得冠军。这种极深层的残差表示在其他识别任务上也展现出卓越的泛化能力，使我们在ILSVRC与COCO 2015竞赛中相继斩获ImageNet检测、ImageNet定位、COCO检测及COCO分割五项冠军。这些有力证据表明残差学习原理具有普适性，我们期待其能应用于其他视觉及非视觉问题。

2. 相关工作

残差表示法。在图像识别领域，VLAD [18]通过相对于字典的残差向量进行编码，而Fisher向量[30]可视为VLAD的概率版本[18]。这两种方法均为图像检索与分类提供强大的浅层表示[4, 47]。在向量量化领域，研究表明编码残差向量[17]比编码原始向量更有效。

在低级视觉与计算机图形学领域，为求解偏微分方程（PDEs），广泛应用的多网格法[3]将系统重构为多尺度子问题，其中每个子问题负责处理粗尺度与细尺度之间的残差解。多网格法的替代方案是分层基预条件处理[44, 45]，该方法依赖于表示两个尺度间残差向量的变量。研究表明[3, 44, 45]，相较于不了解残差性质的标准求解器，这些求解器收敛速度显著更快。这些方法表明，良好的重构或预条件处理能够简化优化过程。

捷径连接。导致捷径连接的实践与理论[2, 33, 48]已长期受到研究。训练多层感知器（MLP）的早期实践是添加从网络输入到输出的线性连接层[33, 48]。在[43, 24]中，为解决梯度消失/爆炸问题，将若干中间层直接连接至辅助分类器。文献[38, 37, 31, 46]提出通过短路连接实现层响应、梯度及传播误差中心化的方法。在[43]中，“Inception”层由一条短路分支和若干深层分支构成。

与本研究同期出现的“高速公路网络”[41, 42]采用带门控函数的捷径连接[15]。这些门控函数依赖数据且包含参数，而我们的恒等捷径则无需参数。当门控捷径“关闭”（趋近于零）时，高速公路网络中的层实现非残差函数。相反，我们的模型始终学习残差函数；恒等短路从不关闭，所有信息持续传递，同时学习额外的残差函数。此外，

网络在深度极度增加时（例如超过100层）并未展现出准确率提升。

3. 深度残差学习

3.1. 残差学习

让我们将 $H(x)$ 视为一个基础映射，由若干堆叠层（不一定是整个网络）进行拟合，其中 x 表示输入到这些层中的第一层。若假设多个非线性层可渐近逼近复杂函数²，则等同于假设它们能渐近逼近残差函数，即 $H(x) - x$ （假设输入与输出维度相同）。因此与其期望堆叠层拟合 $H(x)$ ，我们明确让这些层拟合残差函数 $F(x) := H(x) - x$ 。原始函数由此转化为 $F(x) + x$ 。尽管两种形式均能渐近逼近目标函数（如假设所述），但学习难度可能存在差异。

这种重新表述源于关于退化问题（图1左侧）的反直觉现象。正如我们在引言中讨论的那样，如果新增层可构造为恒等映射，那么更深的模型其训练误差不应大于较浅的对应模型。降解问题表明，求解器可能难以通过多重非线性层逼近恒等映射。采用残差学习重构后，若恒等映射为最优解，求解器只需将多重非线性层的权重驱动至零即可趋近恒等映射。

在实际案例中，恒等映射通常并非最优解，但我们的重新表述有助于对问题进行预处理。若最优函数更接近恒等映射而非零映射，求解器参照恒等映射寻找扰动项应比学习全新函数更为容易。实验结果（图7）表明，所学习的残差函数通常具有较小的响应，这表明恒等映射提供了合理的预处理条件。

3.2. 通过捷径实现恒等映射

我们每隔几个堆叠层就采用残差学习。图2展示了一个基本单元。严格来说，本文考虑的基本单元定义为：

$$y = F(x, \{W_i\}) + x. \quad (1)$$

其中 x 和 y 分别为所考虑层的输入与输出向量。函数 $F(x, \{W_i\})$ 表示待学习的残差映射关系。以图2所示的双层结构为例， $F = W_2\sigma(W_1x)$ ，其中 σ 表示

² 然而该假设仍属未解问题，详见[28]。

为简化记法，省略了ReLU[29]函数与偏置项。运算 $F + x$ 通过短路连接与元素级加法实现。我们在加法后采用第二种非线性函数（ $\sigma(y)$ ，见图2）。

式(1)中的捷径连接既未引入额外参数，也未增加计算复杂度。这不仅在实践中极具吸引力，对于我们比较普通网络与残差网络也至关重要。当残差网络与普通网络同时具备相同参数数、深度、宽度及计算成本（忽略不计的逐元素加法除外）时，我们才能进行公平比较。此时方程(1)中 x 与 F 的维度必须相等。若存在差异（例如改变输入/输出通道数），可通过短接连接执行线性投影 $W(s)$ ，使维度匹配。通道时），可通过短接连接执行线性投影 W_s 以匹配维度：

$$y = F(x, \{W_i\}) + W_s x. \quad (2)$$

我们也可在式(1)中使用方阵 W_s 。但实验将证明，单位映射足以解决降解问题且更经济，因此 W_s 仅在匹配维度时使用。

残差函数 F 的形式具有灵活性。本文实验采用具有两层或三层的 F 函数（图5），但理论上可支持更多层级。若 F 仅含单层，则式(1)类似于线性层： $y = W_1x + x$ ，我们未观察到此结构的优势。需特别说明的是，尽管为简化起见上述符号仅适用于全连接层，但同样适用于卷积层。函数 $F(x, \{W_i\})$ 可表示多层卷积结构，其中元素级加法操作在两个特征图上按通道逐通道进行。

3.3. 网络架构

我们测试了多种基础/残差网络，并观察到一致的现象。为提供讨论实例，我们描述了两个针对ImageNet的数据集模型：

基础网络。我们的基础基线模型（图3中）主要借鉴了VGG网络[40]的设计理念（图3左）。卷积层主要采用 3×3 滤波器，遵循两条简单设计规则：(i) 对于相同输出特征图尺寸，各层滤波器数量保持一致；(ii) 若特征图尺寸减半，则滤波器数量翻倍，以保持每层的时间复杂度不变。我们通过步长为2的卷积层直接执行下采样。网络末端包含全局均值池化层及带softmax的1000维全连接层。图3（中）所示模型共包含34个加权层。

值得注意的是，相较于VGG网络[40]（图3左），本模型滤波器数量更少且复杂度更低。34层基线模型的浮点运算量（乘法运算）为36亿次，仅为VGG-19（196亿次）的18%。




图3. ImageNet的网络架构示例。左：作为参考的VGG-19模型[40]（196亿次浮点运算）。中间：34个参数层的普通网络（36亿FLOPs）。右侧：34个参数层的残差网络（36亿FLOPs）。虚线捷径可增加维度。表1展示更多细节及其他变体。

残差网络。基于上述基础网络，我们将网络映射至其对应的残差版本。当输入与输出维度相同时（图3中实线表示的捷径），可直接使用恒等捷径（式(1)）。当维度增加时（图3中虚线表示的捷径），我们考虑两种方案：(A) 保持恒等映射，通过填充零元素扩展维度。此方案无需额外参数；(B) 采用式(2)中的投影缩短方案匹配维度（通过 1×1 卷积实现）。两种方案中，当缩短操作跨越不同尺寸的特征图时，均采用步长为2的方式执行。

3.4. 实现方案

我们对ImageNet的数据增强方案遵循[21, 40]中的做法。首先对图像进行缩放，其较短边在[256, 480]范围内随机采样以实现尺度增强[40]。随后从原始图像或其水平翻转图像中随机抽取 224×224 像素区域，并对每个像素执行均值减法[21]。采用[21]中的标准颜色增强方案。遵循[16]的实践，在每次卷积后、激活前应用批量归一化(BN)。权重初始化方式参照[12]，所有基础/残差网络均从零开始训练。采用梯度下降法(SGD)，小批量大小设为256。学习率初始值设为0.1，当误差趋于平稳时每轮减小10倍，模型训练总迭代次数上限为 60×10^4 次。采用权重衰减率0.0001与动量0.9。遵循[16]的实践，未使用dropout技术[13]。

在测试中，为进行对比研究，我们采用标准的10个作物测试集[21]。为获得最佳效果，我们采用[40, 12]中提出的全卷积形式，并对多尺度下的评分进行平均（图像经缩放处理，使其短边尺寸为{224, 256, 384, 480, 640}）。

4. 实验

4.1. ImageNet分类

我们在包含1000个类别的ImageNet 2012分类数据集[35]上评估本方法。模型在128万张训练图像上训练，并在5万张验证图像上评估。同时获取测试服务器报告的10万张测试图像最终结果，评估顶1和顶5错误率。

基础网络。首先评估18层与34层基础网络。34层基础网络如图3（中）所示。

18层普通网络结构类似。详见表1中的具体架构。

表2结果表明，更深的34层普通网络验证误差高于较浅的18层普通网络。为探究原因，图4（左）对比了两者的训练过程中的训练/验证误差。我们观察到性能退化问题——

层名	输出尺寸	18层	34层	50层	101层	152层
conv1	112×112	7×7, 64, 步长2				
卷积2 _残	56×56	3×3 最大池, 步长2				
		3×3, 64 3×3, 64 ×2	3×3, 64 3×3, 64 ×3	1×1, 64 3×3, 64□ ×3 1×1, 256	1×1, 64 3×3, 64□ ×3 1×1, 256	1×1, 64 3×3, 64□ ×3 1×1, 256
conv3_x	28×28	3×3, 128 3×3, 128 ×2	3×3, 128 3×3, 128 ×4	1×1, 128 3×3, 128□ ×4 1×1, 512	1×1, 128 3×3, 128□ ×4 1×1, 512	1×1, 128 3×3, 128□ ×8 1×1, 512
conv4_x	14×14	3×3, 256 3×3, 256 ×2	3×3, 256 3×3, 256 ×6	1×1, 256 3×3, 256□ ×6 1×1, 1024	1×1, 256 3×3, 256□ ×23 1×1, 1024	1×1, 256 3×3, 256□ ×36 1×1, 1024
conv5_x	7×7	3×3, 512 3×3, 512 ×2	3×3, 512 3×3, 512 ×3	1×1, 512 3×3, 512□ ×3 1×1, 2048	1×1, 512 3×3, 512□ ×3 1×1, 2048	1×1, 512 3×3, 512□ ×3 1×1, 2048
1×1		平均池, 1000维全连接层, 软最大似然				
浮点运算次数		1.8×10 ⁹	3.6×10 ⁹	3.8×10 ⁹	7.6×10 ⁹	11.3×10 ⁹

表1. ImageNet架构。括号内显示构建模块（参见图5），括号内数字表示堆叠的模块数量。下采样通过步长为2的conv3 1、conv4 1和conv5 1实现。




图4. ImageNet训练曲线。细线表示训练误差，粗线表示中心裁剪区域的验证误差。左侧：18层与34层的普通网络。右侧：18层与34层的ResNet网络。图中残差网络相较于普通网络未增加额外参数。

	普通网络	ResNet
18层	27.94	27.88
34层	28.54	25.03

表2. ImageNet验证集上的Top-1错误率（%，10-crop测试）。此处ResNet相较于其基础版本未增加额外参数。图4展示了训练流程。

34层普通网络在整个训练过程中训练误差更高，尽管18层普通网络的解空间是34层网络解空间的子空间。

我们认为这种优化困难不太可能由梯度消失引起。这些普通网络采用BN[16]进行训练，确保前向传播信号具有非零方差。我们还验证了在BN机制下，后向传播梯度具有健康的范数。因此正向与反向信号均未消失。事实上，34层普通网络仍能达到具有竞争力的准确率（表3），表明求解器在一定程度上有效。我们推测深度普通网络可能存在指数级低收敛速率，这影响了

减少训练误差³。此类优化困难的原因将在未来进行研究。

残差网络。接下来评估18层与34层残差网络（ResNet）。基线架构与上述纯卷积网络相同，区别在于为每对3×3滤波器添加了如图3（右）所示的捷径连接。首次对比（表2与图4右侧）中，所有捷径采用恒等映射，维度扩展时使用零填充（选项A）。因此相较于普通网络，其参数数量未增加。

从表2和图4可得出三项主要观察：首先，残差学习使情况逆转——34层ResNet优于18层ResNet（提升2.8%）。更重要的是，34层ResNet展现出显著更低的训练误差，并能泛化到验证数据集。这表明在该设置下退化问题得到有效解决，我们成功通过增加深度获得了精度提升。

其次，相较于基础模型，34层ResNet在

³我们尝试了更多训练迭代次数（3倍），但仍观察到性能退化问题，这表明仅通过增加迭代次数无法有效解决这个问题。

模型	top-1 误差	top-5 误差
VGG-16 [40]	28.07	9.33
GoogLeNet [43]	-	9.15
PReLU-net [12]	24.27	7.38
普通-34	28.54	10.02
ResNet-34 A	25.03	7.76
ResNet-34 B	24.52	7.46
ResNet-34 C	24.19	7.40
ResNet-50	22.85	6.71
ResNet-101	21.75	6.05
ResNet-152	21.43	5.71

表3. ImageNet验证集上的误差率（%，10次采样测试）。VGG-16基于我们的测试。ResNet-50/101/152采用方案B，仅使用投影实现维度提升。

方法	前5名错误	top-5 误差
VGG [40] (ILSVRC'14)	-	8.43 [†]
GoogLeNet [43] (ILSVRC'14)	-	7.89
VGG [40] (v5)	24.4	7.1
PReLU-net [12]	21.59	5.71
BN-inception [16]	21.99	5.81
ResNet-34 B	21.84	5.71
ResNet-34 C	21.53	5.60
ResNet-50	20.74	5.25
ResNet-101	19.87	4.60
ResNet-152	19.38	4.49

表 4. 单模型在 ImageNet 验证集上的错误率（%）（除[†]标记项外，其余结果基于测试集报告）。

方法	前5类错误率（测试集）
VGG [40] (ILSVRC'14)	7.32
GoogLeNet [43] (ILSVRC'14)	6.66
VGG [40] (v5)	6.8
PReLU-net [12]	4.94
BN-inception [16]	4.82
ResNet (ILSVRC'15)	3.57

表5. 集成模型的错误率（%）。前5错误率基于ImageNet测试集，由测试服务器报告。

ResNet将top-1错误率降低了3.5%（表2），这得益于训练误差的成功降低（图4右侧与左侧对比）。该对比验证了残差学习在极端深度系统中的有效性。

最后需指出，18层纯卷积网络与残差网络的准确率相当（表2），但18层ResNet收敛速度更快（图4右侧与左侧对比）。当网络深度"不过分"（此处为18层）时，当前的SGD求解器仍能为普通网络找到良好解。此时ResNet通过在早期阶段提供更快收敛性，有效简化了优化过程。




图5. 针对ImageNet的更深残差函数F。左图：与图3中ResNet-50/101/152相同的构建模块（基于56×56特征图）。34。右：ResNet-50/101/152的"瓶颈"构建模块。

身份认同与投射捷径。我们已经证明

无参数的恒等缩短路径有助于训练。接下来我们研究投影缩短路径（式(2)）。表3比较了三种方案：(A) 使用零填充缩短路径增加维度，且所有缩短路径均为无参数（与表2和图4右侧相同）；(B) 仅对增加维度使用投影缩短，其余采用恒等缩短；(C) 所有缩短均为投影。表3显示三种方案均显著优于基础模型，其中B略优于A。我们认为这是因为A方案中零填充维度确实无法进行残差学习。C方案略优于B方案，我们认为这是由于大量（13个）投影捷径引入了额外参数所致。但A/B/C方案间的微小差异表明，投影捷径并非解决降维问题的必要手段。因此本文后续部分不采用C方案，以减少内存/时间复杂度及模型规模。恒等捷径对于不增加复杂度尤为重要。

下面介绍的瓶颈架构。

更深的瓶颈架构。接下来我们将描述针对ImageNet的更深神经网络。出于对可承受训练时间的考量，我们将基本单元修改为**瓶颈**设计⁴。对于每个残差函数F，我们采用3层堆叠结构替代原有的2层设计（图5）。这三层分别为1×1、3×3和1×1卷积层，其中1×1卷积层负责先缩减再扩展（恢复）维度，使3×3卷积层成为输入/输出维度较小的瓶颈层。图5展示了该设计的示例，两种设计具有相似的时间复杂度。

无参数的恒等短路对瓶颈架构尤为重要。若将图5（右）中的恒等短路替换为投影，可证明时间复杂度与模型规模将翻倍——因短路连接了两个高维端点。因此恒等短路能为瓶颈设计提供更高效的模型。

50层ResNet：我们将

⁴ 更深的非瓶颈ResNet（如图5左侧所示）虽能通过增加深度提升精度（如CIFAR-10数据集所示），但其经济性不及瓶颈ResNet。因此瓶颈设计的采用主要基于实用考量。我们进一步注意到，普通网络的性能退化问题在瓶颈设计中同样存在。

采用3层瓶颈块构建的34层网络，最终形成50层ResNet（表1）。我们采用选项B进行维度扩展。该模型具有38亿次浮点运算能力。

101层与152层ResNet：通过增加3层模块构建101层与152层ResNet（表1）。值得注意的是，尽管深度显著增加，152层ResNet（113亿FLOPs）的复杂度仍低于VGG-16/19网络（153/196亿FLOPs）。

50层/101层/152层ResNet在准确率上均显著超越34层模型（见表3和表4）。我们未观察到精度衰减现象，因此在深度大幅增加的同时获得了显著的准确率提升。所有评估指标均验证了深度增加带来的益处（见表3和表4）。

与最先进方法的比较。表4中我们对比了此前最佳的单模型结果。我们的基线34层ResNet已达到极具竞争力的准确率。152层ResNet的单模型验证集前5错误率为4.49%，该单模型结果超越了所有先前集成方法的结果（表5）。我们将六种不同深度的模型组合成集成模型（提交时仅包含两个152层模型），在测试集上获得3.57%的Top-5错误率（表5）。该方案荣获*LSVRC 2015 竞赛冠军*。

4.2. CIFAR-10数据集分析

我们对CIFAR-10数据集[20]进行了深入研究，该数据集包含5万张训练图像和1万张测试图像，共10个类别。实验在训练集上进行训练并在测试集上评估。我们关注极深网络的行为表现而非突破最先进结果，因此刻意采用如下简化架构：

基础/残差架构遵循图3（中/右）所示形式。网络输入为32×32图像，并已进行像素级均值减法。第一层采用3×3卷积。随后使用6n层的堆叠结构，分别对尺寸为{32, 16, 8}的特征图进行3×3卷积，每种特征图尺寸对应2n层。滤波器数量分别为{16, 32, 64}。通过步长为2的卷积实现子采样。网络末端包含全局平均池化层、10路全连接层及softmax分类器。总计包含6n+2个堆叠加权层。架构概要如下表所示：

输出图大小	32×32	16×16	8×8
# 层数	$1+2n$	$2n$	$2n$
滤波器数量	16	32	64

当使用捷径连接时，它们连接到3×3层的成对结构（总计3n条捷径）。在本数据集上，我们始终采用恒等捷径（即选项A），

方法			误差率 (%)
最大输出 [9]			9.38
NIN [25]			8.81
DSN [24]			8.22
	# 层数	参数数	
FitNet [34]	19	250万	8.39
高速公路 [41, 42]	19	2.3M	7.54 (7.72±0.16)
高速公路 [41, 42]	32	1.25M	8.80
ResNet	20	0.27M	8.75
ResNet	32	0.46M	7.51
ResNet	44	0.66M	7.17
ResNet	56	0.85M	6.97
ResNet	110	170万	6.43 (6.61±0.16)
ResNet	1202	19.4M	7.93

表6. CIFAR-10测试集分类误差。所有方法均采用数据增强。对于ResNet-110，我们运行5次并按[42]所示展示"最佳(均值±标准差)"。

因此我们的残差模型与基础模型具有完全相同的深度、宽度和参数数量。

采用权重衰减0.0001与动量0.9，沿用[12]中的权重初始化方案及[16]的批量归一化，但未启用dropout。模型在双GPU上以128批量大小训练。初始学习率设为0.1，在32k和48k次迭代时分别减至十分之一，并在64k次迭代时终止训练（该阈值基于45k训练集/5k验证集的分割数据确定）。训练阶段采用[24]中简易数据增强方案：在图像四边各填充4像素，从填充图像或其水平翻转图中随机抽取32×32裁剪区域。测试阶段仅评估原始32×32图像的单视图。

我们比较了 $n = \{3, 5, 7, 9\}$ 的情况，由此得到20层、32层、44层和56层的网络。图6（左）展示了普通网络的行为特征。深度增加导致普通网络性能下降，层数越深训练误差越高。该现象与ImageNet（图4左）和MNIST（参见[41]）中的情况相似，表明此类优化困难属于根本性问题。

图6（中）展示了ResNet的行为。同样类似于ImageNet案例（图4右），我们的ResNet成功克服了优化困难，并在深度增加时展现出精度提升。

我们进一步探索 $n=18$ 参数设置，由此构建出110层的ResNet。在此情况下，我们发现初始学习率0.1略高导致收敛启动困难⁵。因此我们采用0.01进行预热训练，直至训练误差低于80%（约400次迭代），随后恢复至0.1继续训练。其余学习计划与先前操作一致。该110层网络收敛良好（图6中）。其参数数量少于其他深而薄的网络

⁵ 初始学习率设为0.1时，该模型在数个 epoch 后开始收敛（误差<90%），但最终仍能达到相近精度。




图6. CIFAR-10数据集训练曲线。虚线表示训练误差，粗线表示测试误差。左侧：基础网络。误差左图：基础模型-110的准确率高于60%且未显示。中图：ResNet模型。右图：具有110层和1202层的ResNet模型。




图7. CIFAR-10数据集上各层响应的标准差 (std)
10数据集上各层响应的标准差 (std)。响应值为经批归零处理、非线性变换前的 3×3 层输出。上图：按原始顺序展示各层响应；下图：响应值按降序排列。

尽管采用的网络结构（如FitNet[34]和Highway[41]，见表6）并非最先进，但其性能仍处于顶尖水平（6.43%，见表6）。

层响应分析。图7展示了各层响应的标准差 (std)。这些响应是每个 3×3 层在批归零 (BN) 处理后、其他非线性操作 (ReLU/加法) 前的输出。对于ResNet，该分析揭示了残差函数的响应强度。图7表明ResNet的响应值普遍小于其普通对应网络。这些结果支持我们的基本假设（第3.1节）：残差函数的响应值通常比非残差函数更接近零。我们还注意到，更深层的ResNet响应幅度更小，如图7中ResNet-20、56和110的对比所示。层数增加时，ResNet中单层对信号的修改程度趋于减弱。

探索千层以上架构。我们构建了层数超过1000层的极端深度模型。设定 $n=200$ 后形成1202层网络，并按前述方法训练。本方法未出现优化困难，该 10^3 层网络最终实现了训练误差 $<0.1\%$ （图6右侧）。其测试误差仍相当良好（7.93%，表6）。

但此类激进深度模型仍存在未解难题。尽管两者均采用

训练数据	07+12	07++12
测试数据	VOC 07 测试	VOC 12 测试
VGG-16	73.2	70.4
ResNet-101	76.4	73.8

表7. 基于基线Faster R-CNN在PASCAL VOC 2007/2012测试集上的目标检测mAP (%)。更优结果详见附录。

指标	mAP@0.5	mAP@[0.5, 0.95]
VGG-16	41.5	21.2
ResNet-101	48.4	27.2

表8. 基于基线Faster R-CNN在COCO验证集上的目标检测mAP (%)。更优结果详见附录。

具有相似的训练误差。我们认为这是由于过拟合所致。对于如此小的数据集而言，1202层网络可能过于庞大（1940万参数）。在该数据集上，采用强正则化技术（如maxout[9]或dropout[13]）可获得最佳结果（[9, 25, 24, 34]）。本文未采用maxout/dropout技术，仅通过设计深度且层数较少的架构实现正则化，以避免分散对优化难点的关注。但结合更强的正则化手段或可提升效果，这将是未来研究方向。

4.3. PASCAL与MS COCO数据集上的目标检测

本方法在其他识别任务上展现出良好的泛化性能。表7和表8展示了在PASCAL VOC 2007和2012数据集上的目标检测基线结果。[5] 和 COCO [26] 数据集上进行测试。我们采用 *Faster R-CNN* [32] 作为检测方法。本文重点探讨用 ResNet-101 替代 VGG-16 [40] 带来的性能提升。两种模型在检测实现（详见附录）上保持一致，因此性能提升完全归功于更优的网络结构。最显著的是，在具有挑战性的COCO数据集上，我们获得了COCO标准指标mAP@[0.5, .95]提升6.0%，相对提升达28%。该提升完全源于学习到的表示能力。

基于深度残差网络，我们在ILSVRC与COCO 2015竞赛的多项赛道中夺得冠军：Im-ageNet检测、ImageNet定位、COCO检测及COCO分割。详情见附录。

参考文献

- [1] Y. Bengio, P. Simard, P. Frasconi. 《梯度下降法难以学习长期依赖关系》. 《IEEE 神经网络学报》, 5(2):157–166, 1994.
- [2] C. M. Bishop. 《神经网络模式识别》. 牛津大学出版社, 1995.
- [3] W. L. Briggs, S. F. McCormick 等. 《多网格教程》. Siam, 2000.
- [4] K. Chatfield, V. Lempitsky, A. Vedaldi, and A. Zisserman. 细节决定成败：近期特征编码方法评估. 发表于*BMVC会议论文集*, 2011.
- [5] M. Everingham, L. Van Gool, C. K. Williams, J. Winn, 和 A. Zisserman. 《Pascal 视觉对象类别 (VOC) 挑战赛》. 《国际计算机视觉杂志》, 第303–338页, 2010年.
- [6] R. Girshick. 快速R-CNN. 发表于*ICCV*, 2015.
- [7] R. Girshick, J. Donahue, T. Darrell, 和 J. Malik. 《用于精确目标检测与语义分割的丰富特征层次结构》. 发表于 *CVPR*, 2014.
- [8] X. Glorot 和 Y. Bengio. 理解深度前馈神经网络训练的困难. 发表于 *AISTATS*, 2010.
- [9] I. J. Goodfellow, D. Warde-Farley, M. Mirza, A. Courville, 和 Y. Bengio. Maxout网络. *arXiv:1302.4389*, 2013.
- [10] K. He 和 J. Sun. 受限时间成本下的卷积神经网络. 发表于 *CVPR*, 2015.
- [11] K. He, X. Zhang, S. Ren, and J. Sun. 深度卷积网络中用于视觉识别的空间金字塔池化. 发表于*ECCV*, 2014.
- [12] K. He, X. Zhang, S. Ren, J. Sun. 深入研究整流器：在ImageNet分类任务上超越人类水平. 发表于*ICCV*, 2015.
- [13] G. E. Hinton, N. Srivastava, A. Krizhevsky, I. Sutskever, and R. R. Salakhutdinov. 通过防止特征检测器的协同适应来改进神经网络. *arXiv:1207.0580*, 2012.
- [14] S. Hochreiter. 动态神经网络研究. 硕士学位论文, 慕尼黑工业大学, 1991年。
- [15] S. Hochreiter 和 J. Schmidhuber. 长短期记忆网络. *神经计算*, 9(8):1735–1780, 1997.
- [16] S. Ioffe 和 C. Szegedy. 批量归一化：通过减少内部协变量偏移加速深度网络训练. 发表于*ICML*, 2015.
- [17] H. Jegou, M. Douze, 和 C. Schmid. 《最近邻搜索中的积量化》. *TPAMI*, 33, 2011.
- [18] H. Jegou, F. Perronnin, M. Douze, J. Sanchez, P. Perez, 和 C. Schmid. 《局部图像描述符向紧凑编码的聚合》. *TPAMI*, 2012年。
- [19] Y. Jia, E. Shelhamer, J. Donahue, S. Karayev, J. Long, R. Girshick, S. Guadarrama, and T. Darrell. Caffe：用于快速特征嵌入的卷积架构. *arXiv:1408.5093*, 2014.
- [20] A. Krizhevsky. 从微小图像中学习多层特征. 技术报告, 2009.
- [21] A. Krizhevsky, I. Sutskever, and G. Hinton. 基于深度卷积神经网络的ImageNet分类. 发表于*NIPS*, 2012.
- [22] Y. LeCun, B. Boser, J. S. Denker, D. Henderson, R. E. Howard, W. Hubbard, and L. D. Jackel. 反向传播在手写邮政编码识别中的应用. *神经计算*, 1989.
- [23] Y. LeCun, L. Bottou, G. B. Orr, K.-R. Müller. 《高效反向传播》. 载于《神经网络：行业诀窍》，第9-50页. Springer出版社, 1998.
- [24] C.-Y. Lee, S. Xie, P. Gallagher, Z. Zhang, Z. Tu. 深度监督网络. *arXiv:1409.5185*, 2014.
- [25] 林泰宇、陈庆、严思. 网络中的网络. *arXiv:1312.4400*, 2013年。
- [26] 林天佑、玛丽·玛伊尔、斯蒂芬·贝隆吉、约翰·海斯、彼得·佩罗纳、达伦·拉马南、
- P. Dollár, 和 C. L. Zitnick. 微软COCO：上下文中的常见物体. 收录于*ECCV*. 2014.
- [27] J. Long, E. Shelhamer, T. Darrell. 基于全卷积网络的语义分割. 发表于*CVPR*, 2015.

- [28] G. 蒙图法尔、R. 帕斯卡努、K. 赵、Y. 本吉奥。关于神经网络线性区域数量的研究。发表于 *NIPS*, 2014年。
- [29] V. Nair 和 G. E. Hinton. 整流线性单元改进限制玻尔兹曼机。发表于 *ICML*, 2010。
- [30] F. Perronnin 和 C. Dance. 基于视觉词汇的费雪核在图像分类中的应用。发表于 *CVPR*, 2007。
- [31] T. Raiko, H. Valpola, Y. LeCun. 感知器中的线性变换简化深度学习。发表于 *AISTATS*, 2012。
- [32] S. Ren, K. He, R. Girshick, 和 J. Sun. 更快R-CNN: 基于区域提案网络的实时目标检测。发表于 *NIPS*, 2015。
- [33] B. D. Ripley. 《模式识别与神经网络》。剑桥大学出版社, 1996。
- [34] A. Romero, N. Ballas, S. E. Kahou, A. Chassang, C. Gatta, 和 Y. Bengio. Fitnets: 浅层深度网络的启示。发表于 *ICLR*, 2015。
- [35] O. Russakovsky, J. Deng, H. Su, J. Krause, S. Satheesh, S. Ma, 黄志强、A. Karpathy、A. Khosla、M. Bernstein 等。ImageNet大规模视觉识别挑战赛。arXiv:1409.0575, 2014。
- [36] A. M. Saxe, J. L. McClelland, 和 S. Ganguli. 深度线性神经网络中学习非线性动力学的精确解。arXiv:1312.6120, 2013。
- [37] N. N. Schraudolph. 基于因子中心化分解的加速梯度下降法。技术报告, 1998。
- [38] N. N. Schraudolph. 神经网络梯度因子中心化。载于《神经网络: 行业诀窍》, 第207–226页。Springer出版社, 1998年。
- [39] P. Sermanet, D. Eigen, X. Zhang, M. Mathieu, R. Fergus, Y. Le-Cun. 卷积网络的综合识别、定位与检测: Overfeat系统。发表于 *ICLR*, 2014。
- [40] K. Simonyan 和 A. Zisserman. 《用于大规模图像识别的超深卷积网络》。发表于 *ICLR*, 2015。
- [41] R. K. Srivastava, K. Greff, 和 J. Schmidhuber. 高速公路网络。arXiv:1505.00387, 2015年。
- [42] R. K. Srivastava, K. Greff, 和 J. Schmidhuber. 训练超深神经网络。arXiv:1507.06228, 2015。
- [43] C. Szegedy, W. Liu, Y. Jia, P. Sermanet, S. Reed, D. Anguelov, D. Erhan、V. Vanhoucke 和 A. Rabinovich. 卷积深度化。 *CVPR*, 2015。
- [44] R. Szeliski. 基于分层基函数的快速曲面插值。 *TPAMI*, 1990。
- [45] R. Szeliski. 《局部自适应分层基函数预条件处理》。发表于 *SIGGRAPH*, 2006。
- [46] T. Vatanen, T. Raiko, H. Valpola, 和 Y. LeCun. 《将随机梯度推向二阶方法——非线性变换中的反向传播学习》。收录于《神经信息处理》, 2013年。
- [47] A. Vedaldi 和 B. Fulkerson. VLFeat: 开放且可移植的计算机视觉算法库, 2008年。
- [48] W. Venables 和 B. Ripley. 《S-Plus现代应用统计学》, 1999年。
- [49] M. D. Zeiler 与 R. Fergus. 《卷积神经网络的可视化与理解》。收录于 *ECCV*, 2014年。